

#### Лекция 6

### Особенности реализации алгоритмов трассировки лучей на CUDA

- Лекторы:
  - Фролов В.А. (ВМиК МГУ)
  - Игнатенко А.В. (ВМиК МГУ)
  - Боресков А.В. (ВМиК МГУ)
  - Харламов А.А. (NVIDIA)



#### План

- RT что, зачем и как?
- Метод грубой силы
  - CUDA
- Ускоряющие структуры
  - Регулярные и иерархические сетки
  - BVH
  - kd деревья



### Ray Tracing

• Фотореалистичный синтез изображений





POV-Ray



### Ray Tracing

• Фотореалистичный синтез изображений





POV-Ray



### Real Time Ray Tracing

• Скорость в ущерб качеству





# Ray Tracing PHOLI "ПАРАЛЛЕЛЬНЫЕ ВЫЧИСЛЕНИЯ" APPLIED PARALLEL COMPUTING EAR CENTER

#### • Точность

- Path tracing
- Фотонные карты
- Распределенная трассировка лучей (стохастическая)


#### • Скорость


- Обратная трассировка лучей
- Растеризация + обратная трассировка лучей

### Обратная трассировка лучей

#### • Алгоритм

• Первичные, теневые, отраженные лучи










### Ray Tracing

- Представление 3D объектов
  - Аналитическое
  - Меши из треугольников










### Ray Tracing


- Поверхность задана как массив треугольников
- Узкое место поиск пересечения луча с поверхностью
  - 1 000 000 треугольников
  - 1 000 000 лучей
  - => 10<sup>12</sup> операций
  - $(\log(N))^{k*}10^6 (k\sim[1..2])$



#### • Простой вариант

$$Ax + By + Cz + D = 0$$


- Найти t
  - $x = p.x + v.x \cdot t$
  - $y = p.y + v.y \cdot t$
  - $z = p.z + v.z \cdot t$



$$t = -\frac{(A \cdot p.x + B \cdot p.y + C \cdot p.z + D)}{A \cdot v.x + B \cdot v.y + C \cdot v.z}$$

#### • Простой вариант

- t известно
  - z = p + v \* t
  - S = cross(v1-v0, v2-v0)
  - u = cross(v1-z, v0-z)
  - V = cross(v1-z, v2-z)
  - t1 = cross(v2-z, v0-z)
- $|u + v + t1 S| < \varepsilon$



#### • Оптимизированный вариант

• Барицентрические координаты


• 
$$u := u/S$$
,  $v := v/S$ ,  $t1 := t1/S$ 

• 
$$t1 = 1 - u - v$$

$$z(u,v) = (1-u-v)v1 + uv2 + vv0$$
$$z(t) = p + td$$

$$p + td = (1 - u - v)v1 + uv2 + vv0$$

• 3 уравнения, 3 неизвестных



#### • Оптимизированный вариант

$$\begin{bmatrix} t \\ u \\ v \end{bmatrix} = \frac{1}{dot(P, E1)} \begin{bmatrix} dot(Q, E2) \\ dot(P, T) \\ dot(Q, D) \end{bmatrix}$$
$$E1 = v1 - v0$$


$$E2 = v2 - v0$$

$$T = p - v0$$

$$P = cross(D, E2)$$

$$Q = cross(T, E1)$$

$$D = v$$



#### • Простой вариант


- Операции (\* : 39, +/- : 53, / : 1)
  - 248-404 тактов

#### • Оптимизированный вариант

- Операции (\* : 23, +/- : 24, / : 1)
  - 132-224 такта

#### • Как считали нижнюю оценку?

- использование mad вместо mul и add
- $4*(N_mul + |N_add N_mul|)$






### Другие примитивы

#### • Бокс – это 6 плоскостей

- (vmin.x r.pos.x) / r.dir.x;
- (vmin.x + rInv.pos.x) \* rInv.dir.x;
- 6 add и 6 mul == 12 mad, 48 тактов

#### • Сфера

- $\sim 13 \text{ mad} + \text{sqrtf} == 52 + 32 = 84 \text{ такта}$
- меньше ветвлений
- Иерархия из сфер не лучше иерархии из боксов




### Multiprocessor Occupancy

• Регистры

occupancy =


max warps



- 8192 регистра на SM
- Блоки по 8х8 нитей
- 128 регистров на нить
  - пусс не дает столько регистров, почему?
  - рег <= 40: 3 блока, 6 warp-ов активны
  - рег <= 32: 4 блока, 8 warp-ов активны
  - рег <= 24: 5 блоков, 10 warp-ов активны
  - рег <= 20: 6 блоков, 12 warp-ов активны
  - рег <= 16: 8 блоков, 16 warp-ов активны

#### • Регистры


- 6 регистров на луч
- 9 регистров на вершины
- 3 регистра на (t, u, v)
- 1 регистр на triNum
- 1 на счетчик в цикле
- 1 как минимум на tid
- 2 на min\_t и min\_id
- 23 уже занято!





Q = cross(T, E1)


D = v


- Организация сетки блоки 8х8
- Что общее для нитей блока?
- 1. Свой луч, свой треугольник
- 2. Свой луч, общий треугольник
- 3. Общий луч, свой треугольник


















```
for (int i=0;i<triNum;i++)
{
    (A,B,C) = tex1Dfetch(tex,i);
    // intersection code
}</pre>
```







```
for (int i=0;i<triNum;i++)
{
    (A,B,C) = tex1Dfetch(tex,i);
    // intersection code
}</pre>
```







```
for (int i=0;i<triNum;i++)
{
    (A,B,C) = tex1Dfetch(tex,i);
    // intersection code
}</pre>
```





Свой луч, общий треугольник





\_shared\_\_\_ s\_triangles[64];


```
threads
```


64

```
s_triangles[id] = g_triangles[id];
__syncthreads();
for (int i=0; i<64; i++)
  (A,B,C) = s_{triangles[i]};
    intersection code
```

• Свой луч, общий треугольник

#### triangles texture, or global






```
__shared__ s_triangles[64];


s_triangles[id] = g_triangles[id];
__syncthreads();

for (int i=0;i<64;i++)
{
    (A,B,C) = s_triangles[i];
    // intersection code
```

• Свой луч, общий треугольник

#### triangles texture, or global






```
__shared__ s_triangles[64];
s_triangles[id] = g_triangles[id];
__syncthreads();


for (int i=0;i<64;i++)
{
    (A,B,C) = s_triangles[i];
    // intersection code
}</pre>
```


• Общий луч, свой треугольник



• Общий луч, свой треугольник

#### triangles texture, or global






```
__shared__ Hit s_tResult[64];
__shared__ Ray ray;

(A,B,C) = g_triangles[id];
// intersection code
s_tResult[id] = resHit;
__syncthreads();

ReduceMin(s_tResult, 64);
// s_tResult[0] - ближайшее
пересечение
```

• Общий луч, свой треугольник

#### triangles texture, or global



#### threads

shared memory

ReduceMin

Ядро занимает 21 регистр

```
__shared__ Hit s_tResult[64];
__shared__ Ray ray;
```

```
(A,B,C) = g_triangles[id];
// intersection code
s_tResult[id] = resHit;
__syncthreads();
```

ReduceMin(s\_tResult, 64); // s\_tResult[0] – ближайшее пересечение


- Организация сетки блоки 8х8
- Что общее для нитей блока?
- Свой луч, свой треугольник (100%)
- Свой луч, общий треугольник (130%)
- Общий луч, свой треугольник (40-50%)





### Архитектура рейтрейсера

- Ядро пересечений 32 регистра
- Нужно разбить алгоритм трассировки на несколько ядер





### Архитектура рейтрейсера

- Traversal kernel блоки 16х4
- Как хранить геометрию?


```
Traversal kernel
struct Vertex
   float3 pos[3];
                                                         Intersection kernel
   float3 norm[3];
   float2 texCoord;
   uint materialIndex;
                                                           Shade kernel
};
struct Triangle
                                  Vertex array:
   uint v[3];
};
                                  Index array:
```



### Архитектура рейтрейсера


- Traversal kernel блоки 16х4
- Дублирование геометрии


```
struct Triangle
  vec3f v[3];
  unsigned int selfIndex;
}; // 40
struct Sphere
  PackedSphere3f sph;
  unsigned int selfIndex;
  unsigned int dummy;
}; // 24
// выборки по float2
```






## Регулярная сетка











### Регулярная сетка

• Регулярная сетка

```
if (tMaxX <= tMaxY && tMaxX <= tMaxZ)</pre>
  tMaxX += tDeltaX;
  x += step X;
else if (tMaxY <= tMaxZ && tMaxY <= tMaxX)
  tMaxY += tDeltaY;
  y += stepY;
else
  tMaxZ += tDeltaZ;
  z += stepZ;
```








### Регулярная сетка

- Преимущества
  - Просто и быстро строится
  - Простой алгоритм траверса
- Недостатки




- Требует много памяти
- Много повторных пересечений **отвратительно** разбивает геометрию
- Только для небольших сцен (1-50К)





### Регулярная сетка

• Почему сетка плохо разбивает геометрию?





• 7 раз посчитали пересечение с одним и тем же треугольником!



### Иерархическая сетка


- Небольшое число вокселей
- Рекурсивно разбиваем воксели в местах с плотной геометрией








- + Решает проблему чайника на стадионе
- Переход между узлами вычислительно сложен
- + 12 регистров как минимум
- Нужно устранять рекурсию






Bounding Volume Hierarchy







Bounding Volume Hierarchy






Bounding Volume Hierarchy













### • Траверс на СРИ



Стек: L




### • Траверс на СРИ



Стек: L




### • Траверс на СРИ




Стек: L
































#### • Как делать на CUDA?

- Луч 6 регистров
- Бокс 6 регистров
- t\_near, t\_far, 2
- nodeOffset, leftOffset, tid 3

#### • Пересечение луча с боксом


- Минимум по всем 6 плоскостям
  - (vmin[0] + rInv.pos[0]) \* rInv.dir[0];






- Как делать на CUDA?
  - 24 mad-а покрывают латентность текстурной памяти
- Стек на локальной памяти
  - Локальная память это не так медленно, как может показаться
- Бесстековый алгоритм
  - Перебираем массив всегда строго слева направо






```
struct KdTreeNode
{
    float split;
    uint leftOffset: 29;
    uint splitAxis: 2;
    uint leaf: 1;
};
```







```
struct KdTreeNode
{
    float split;
    uint leftOffset: 29;
    uint splitAxis: 2;
    uint leaf: 1;
}
```









```
struct KdTreeNode
{
    float split;
    uint leftOffset: 29;
    uint splitAxis: 2;
    uint leaf: 1;
}
```









```
struct KdTreeNode
{
    float split;
    uint leftOffset: 29;
    uint splitAxis: 2;
    uint leaf: 1;
}
```









```
struct KdTreeNode
{
    float split;
    uint leftOffset: 29;
    uint splitAxis: 2;
    uint leaf: 1;
}
```









```
struct KdTreeNode
{
    float split;
    uint leftOffset: 29;
    uint splitAxis: 2;
    uint leaf: 1;
};
```






- Алгоритм траверса
- Регистры 13 min:
  - луч 6
  - t, tmin, tmax 3
  - node 2
  - tid, stack\_top -2
  - На практике удалось уложиться в 19
  - Стек: локальная память







#### • Алгоритм траверса




Стек:

Текущий узел:



#### • Алгоритм траверса




Стек: R

Текущий узел: L



#### • Алгоритм траверса




Стек: R

Текущий узел: LL



#### • Алгоритм траверса




Стек: LLR, R

Текущий узел: LLL



• Алгоритм траверса




Стек: LLR, R

→ Текущий узел: **LLLR** 



• Алгоритм траверса




Shade kernel

Стек: R

→ Текущий узел: LLR Можно было бы остановиться!



#### • Алгоритм траверса




Стек:

Текущий узел: R



#### • Алгоритм траверса




Стек: RR

→ Текущий узел: RL



#### • Алгоритм траверса




Стек:

Текущий узел: RR



#### • Алгоритм траверса




Shade kernel

Стек:

Текущий узел: RRR Конец, результат: LLR, RRR




#### Где узкое место?






#### Conference Room (281K)








#### • Где узкое место?



**1.5M** 











### Стулья (1.5M)









#### kd-tree vs BVH на CUDA

#### • BVH со стеком на локальной памяти

- Покрывается латентность текстурной памяти
- Меньше глубина
- Алгоритм сложнее, нужно больше регистров
- Лишние плоскости

#### kd-tree

- Экономит регистры
- Можно эффективнее задействовать кэш?
- 1 mad и пара ветвлений на одну tex1Dfetch

